

1. 專案概述與測試目標（翁寧緬）

1.1 背景與設計目標

本專案為大型語言模型自動化評估流程，專為評估異質模型架構在跨學科領域之綜合推理能力、推論延遲與輸出穩定性而設計。從資料抽樣、模型推論、答案解析到結果紀錄皆採模組化設計，並支援本機開源模型與雲端 API 模型的評估系統。

1.2 評估資料集與抽樣策略

評估基準選用多任務語言理解資料集 `cais/mmlu`。為兼顧跨領域評估廣度與測試效率，自 57 個子領域中選擇涵蓋 Humanities、Social Sciences、STEM、Other / Applied Sciences 4 大範疇之 8 門代表性學科：**STEM** (`college_computer_science`, `high_school_mathematics`), **Humanities** (`philosophy`, `world_religions`), **Social Sciences** (`econometrics`, `high_school_psychology`), **Other / Applied Sciences** (`clinical_knowledge`, `professional_law`)

為保證實驗的可重現性，資料抽樣固定 `seed: 42`，並提供兩種評測規模：

1. **Smoke Test**：每科抽樣 10 題（總計 80 題），用於快速驗證資料載入、模型推論與評估流程是否能完整執行。
2. **Demo Benchmark**：用於比較不同模型架構在相同題目上的評測結果。

1.3 評測模型與執行環境

本專案將模型分為本機模型與雲端 API 兩類，並統一執行相同的資料處理、推論與答案評估流程。

- **本機模型（Local Hugging Face）**
 - `Qwen/Qwen2.5-0.5B-Instruct`：作為輕量模型基準，觀察小型模型在 MMLU 多選題上的基本表現。
 - `HuggingFaceTB/SmolLM2-1.7B-Instruct`：作為較大型的輕量模型，觀察模型規模增加後對跨學科題目的影響。
- **雲端模型（API）**
 - `gemini-3.1-flash-lite`：作為雲端 API 模型，與本機模型進行結果、延遲與執行穩定性的比較。（免費額度：RPM15 \ RPD500）

2. 系統建構流程與 AI 協同開發實踐

2.1 免費 AI 工具鏈與三方協同機制

流程採用免費開發工具，建立「AI 生成 → AI 審查 → 人工驗收」的研發閉環。

• **AI 協同開發工作流（兩階段提示工程 / Two-Stage Prompting）：**

- **Stage 1: 實作角色：**初期由 Cursor（Grok 4.6 Medium）建立核心架構與 data_loader.py 初版；Context 滿載後遷移至 Cline（Qwen 3.8 27B、Cohere North-mini-code 等）承接專案 .clinerules，以同模型環境快速生成最小可行性程式碼、型別標註與基礎測試，並在通過本機 pytest、ruff、mypy 檢驗後進入暫停狀態。
- **Stage 2: 審查角色：**於 Cline 同模型環境切換為審查者 Prompt，以對抗式審查挑剔邊界漏洞、記憶體洩漏與例外捕捉死角，完成條件式重構、壓力測試補強，並產出 Milestone 審查日誌與 Git Commit 提案。

• **Human Engineer（驗收決策端 - 本人）：**負責資料抽樣、評估指標、流程架構決策、於最後階段執行測試驗證（pytest / ruff / mypy）與 Git Commit、push。

• 過程中，也會利用 NotebookLM, Gemini, ChatGPT 做知識與文獻梳理，Codex 協作簡報。

2.2 Pipeline 建構與 AI 輔助開發

本專案採循序開發方式建置，依序完成模組實作、AI 輔助 Code Review、離線單元測試、整合測試與版本管理。以下整理八個主要開發階段，以及 AI 在各階段所協助的開發與審查工作；詳細紀錄請參閱 docs/包含各階段協作紀錄或全流程整合紀錄

AI_REVIEW_AND_REFACTOR_LOG.md。

階段	Human Engineer 主導	AI 協作與審查	單元測試
0. 架構規劃 & Scaffolding	定義資料流、模組職責、資料抽樣、seed=42、選定評估指標與 Prompt 規格	建立專案骨架目錄、初始環境依賴、Config 模板與 Git 版本控制規範	架構與規格確定
1. Dataset Loader	定義資料載入流程、資料抽樣嚴謹度與確保抽樣結果可重現	檢查資料型態與選項內容，避免錯誤資料影響評估；建立穩定的題目識別方式，確保資料可追蹤；改善題目抽樣與格式檢查，確保每次執行結果一致。	34 passed (0.08s)
2. Evaluator	規劃評估方式、正確率與執行時間的計算方式	強化答案判讀與錯誤處理，避免誤判答案；統一正確率計算方式，避免異常結果造成評估偏高；改善執行時間統計，避免未完成題目影響平均值。	113 passed (0.11s)
3. Model Interface	制定標準化的輸出格式（包含題號、回答內容與反應時間），並統一	設定初期即時攔截異常參數以防執行中斷、建立連線失敗自動重試機制、自動	194 passed (4.46s)

	整合本機開源模型與雲端 API 的呼叫架構。	濾除本機模型的對話雜訊，並採用輕量模擬進行快速離線驗證。	
4. Runner & Pipeline	排程依序執行防當機、控制發問頻率避免限流，並做到逐題即時存檔與記憶體釋放。	建立強制釋放顯存機制防止切換模型時崩潰、嚴格限制循序排程以杜絕超載、修復日誌變數傳遞錯誤以落實即時存檔，並加固隨機種子的預設容錯邏輯。	290 passed (3.68s)
5. Few-Shot 擴充	定義 Few-Shot 設定優先順序，並確保示範題與測試題完全隔離	改善參數設定、題目組裝與測試流程，確保 Few-Shot 功能正常運作	293 passed (4.91s)
6. 自動化 & 交付	撰寫 Smoke/Demo 腳本、執行真實模型實測與成果固化	協助檢查與文件整理	輸出推論紀錄與評測報表

3. 評估結果與跨模型效能分析

本評估於相同隨機抽樣基準（240 題，固定 seed: 42）下，對比 0-shot 與 5-shot 於不同規模模型之表現：

模型名稱 (參數量 / 部署)	0-shot 準確率	5-shot 準確率	格式失敗 (0 / 5-shot)	平均延遲 (0 / 5-shot)	5-shot 領域 最高 / 最弱
Qwen2.5-0.5B (本機 / 輕量)	40.00%	38.75%	9 題 / 13 題	0.55s / 0.81s	人文 53.3% / STEM 25.0%
SmolLM2-1.7B (本機 / 中型)	49.58%	50.42%	0 題 / 0 題	0.92s / 2.23s	人文 63.3% / 其他 38.3%
Gemini-3.1-Flash-Lite (雲端)	86.67%	86.67%	2 題 / 0 題	7.78s / 2.12s	社科與人文 91.7% / 其他 80.0%

總結：

- 模型能力差異明顯：**Gemini 達 86.67% 展現跨學科推理優勢（社科與人文破 91%）；開源輕量模型（1.7B 為 50.42%、0.5B 為 38.75%）在 STEM 領域明顯受限。
- Few-Shot 不一定對所有模型都有幫助：**中大型模型受益，Gemini 透過 5-shot 格式錯誤歸零；超輕量 0.5B 則因提示詞增長注意力分散，格式錯誤反增至 13 題。
- 提示內容也會影響推論時間：**延遲為純推論時間（不含題間停頓）；Gemini 於 0-shot 輸出長篇推導使耗時達 7.78s，5-shot 約束簡短格式後大幅收斂至 2.12s。